



# MÓDULO DE ESTADÍSTICA SERIES DE TIEMPO

**DIPLOMADO DE  
MATEMÁTICAS Y  
ESTADÍSTICA, MIDE**

Roslán Gómez Nesterkín  
Noviembre 2022

Aviso: Los comentarios y  
opiniones expresados son solo del  
autor y no necesariamente  
reflejan a los del Banco de  
México.

# ENCUESTAS

- A fin de tener una mayor interacción durante las presentaciones...
- Se realizarán algunas encuestas de opinión durante las sesiones...
- A través de la aplicación de celular: **Telegram**
- Favor de adherirse al grupo: **MIDE\_DIP\_MATS\_2022**
- Liga directa: [https://t.me/MIDE\\_DIP\\_MATS\\_2022](https://t.me/MIDE_DIP_MATS_2022)

# PLAN DE LA PRESENTACIÓN

## PARTE 1


- ❖ **ANTECEDENTES:** Series determinísticas, variables aleatorias y estimación.
- ❖ **SERIES DE TIEMPO:** Series Determinísticas, Series de Tiempo, Suma de Variables Aleatorias.
- ❖ **DISTRIBUCIÓN DE SERIES DE TIEMPO:** Límite Central, Función Característica, Caminata Aleatoria.
- ❖ **CARACTERÍSTICAS DE LAS SERIES DE TIEMPO:** Autocorrelación, Estacionalidad.

## PARTE 2

- ❖ **DESCOMPOSICIÓN:** Descomposición de Wold.
- ❖ **MODELOS DE SERIES DE TIEMPO:** Función de auto-correlación, AR, MA.
- ❖ **EJEMPLO:** ¿Predicción al 75%?

## PARTE 3

- ❖ **MODELOS DE SERIES DE TIEMPO:** Función de auto-correlación parcial, ARMA, otras variantes.
- ❖ **OTRAS CARACTERÍSTICAS:** Heteroskedasticidad, Modelo ARCH, Causalidad de Granger, Cointegración.
- ❖ **PRONÓSTICOS:** ARMA / Box-Jenkins.



## PARTE 3 PRONÓSTICOS

# PLAN DE LA PRESENTACIÓN

## PARTE 1


- ❖ ANTECEDENTES
- ❖ SERIES DE TIEMPO
- ❖ DISTRIBUCIÓN DE SERIES DE TIEMPO
- ❖ CARACTERÍSTICAS DE LAS SERIES DE TIEMPO

## PARTE 2

- ❖ DESCOMPOSICIÓN
- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ EJEMPLO

## PARTE 3

- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ OTRAS CARACTERÍSTICAS
- ❖ PRONÓSTICOS



## Motivación para análisis de series de tiempo

### MODELOS ESTOCÁSTICOS

**Robert F. Engle III**  
**Clive W. J. Granger**

Premio Nobel 2003 en Ciencias Económicas “*por métodos para el análisis económico de series de tiempo con volatilidad variable en el tiempo (ARCH).*”

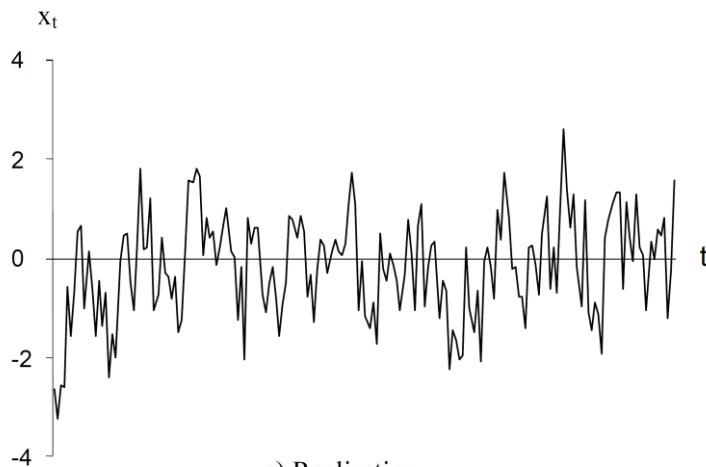


[https://www.nobelprize.org/nobel\\_prizes/economic-sciences/laureates/2003/press.html](https://www.nobelprize.org/nobel_prizes/economic-sciences/laureates/2003/press.html)


- Métodos (matemáticos) para análisis de series de tiempo.
- Modelos (matemáticos) de volatilidad estocástica.
- Modelos (estadísticos) con memoria de largo plazo.
- Metodologías (estadísticas) para identificar causalidad.
- Muchas de las series de tiempo económicas son no-estacionarias.

## Función de Autocorrelación Parcial (PACF) (1/2)

- La modelación con AR( $p$ ) conduce a la pregunta de cuántos términos  $p$  utilizar.
- Una característica de los modelos AR( $p$ ) en procesos estacionarios, es que su función de auto-correlación  $\rho_\tau$ , como función del rezago  $\tau$ , converge asintóticamente a cero.
- Ejemplo: Modelo AR(1) de un proceso aleatorio puro de 240 observaciones con  $\alpha = 0.5$ :



a) Realisation



c) Estimated autocorrelation function with confidence intervals



## Función de Autocorrelación Parcial (PACF) (2/2)

- Asumamos una serie de valores observados  $x = \{x_1, \dots, x_n\}$  y los modelos AR( $p$ ) siguientes:

$$X_t = \phi_{0,1} + \boxed{\phi_{1,1}} X_{t-1} + e_{1,t} \quad p = 1$$

$$X_t = \phi_{0,2} + \phi_{1,2} X_{t-1} + \boxed{\phi_{2,2}} X_{t-2} + e_{2,t} \quad p = 2$$

$$X_t = \phi_{0,3} + \phi_{1,3} X_{t-1} + \phi_{2,3} X_{t-2} + \boxed{\phi_{3,3}} X_{t-3} + e_{3,t} \quad p = 3$$

$\vdots$

- Para cada AR( $p$ ) es posible estimar los parámetros  $\phi_{i,j}$  usando los datos  $x$ , por ejemplo mediante mínimos cuadrados, obteniendo los estimadores  $\hat{\phi}_{i,j}$ .
- El estimador  $\hat{\phi}_{i,i}$  representa el peso del término  $X_{t-i}$ , de modo que como la auto-correlación es asintótica a cero, se esperaría que a partir de un cierto  $p$ , el estimador  $\hat{\phi}_{p+s,p+s}$  sea muy cercano a cero.
- Criterio PACF:** Dada una tolerancia  $\varepsilon > 0$  (nivel de tolerancia preconcebido), escogemos el modelo AR( $p$ ) como aquel a partir del cual el coeficiente  $\hat{\phi}_{i,i}$  sea despreciable:

$$p^* = \min\{p : |\hat{\phi}_{p+s,p+s}| < \varepsilon\}$$

Nota: Este criterio evita sobrecarga de variables (**overfitting**) usadas en el modelo.

## Promedio Móvil Auto Regresivo: (ARMA)

- Un ARMA( $p, q$ ) se refiere a una combinación de un AR( $p$ ) y un MA( $q$ ).

$$X_t = \delta$$

← Término relativo a **tendencia**

$$+ \alpha_1 X_{t-1} + \dots + \alpha_p X_{t-p}$$

← Término relativo a **AR(p)**

$$+ u_t$$

← Término relativo a **aleatoriedad** (en  $t$ )

$$- \beta_1 u_{t-1} - \dots - \beta_q u_{t-q}$$

← Término relativo a **MA(q)**

- De esta manera obtenemos el modelo **ARMA(1,1)**:

$$X_t = \delta + \alpha X_{t-1} + u_t - \beta u_{t-1}$$

**EJERCICIO EN CLASE (10 minutos):** En un modelo **ARMA(1,1)**, sean  $\alpha = -0.8$ ,  $\beta = 0.5$ ,  $u_t \sim N(0,1)$  y  $\delta = 0$ . Si se observan los valores de la realización de  $u_t$  siguientes:  $u_0 = 1$ ,  $u_1 = -1$  y  $u_2 = 0.5$ , ¿cuál sería el valor que tendrían  $X_1$  y  $X_2$  cuando  $X_0 = 0$ ?

## Promedio Móvil Auto Regresivo: Momentos de ARMA(1,1)

(1/2)

- Calculamos el **valor esperado** del proceso estacionario  $X_t$ :

1. Por definición:  $\mathbb{E}[X_t] = \mathbb{E}[\delta + \alpha X_{t-1} + u_t - \beta u_{t-1}] = \delta + \alpha \mathbb{E}[X_{t-1}]$

2. Como  $X_t$  es estacionario, entonces tiene el mismo valor esperado para todo  $t$ :

$$\mu = \mathbb{E}[X_t] = \mathbb{E}[X_{t-1}]$$

3. Tomando los dos resultados anteriores, resolvemos  $\mu$  de la siguiente ecuación:

$$\mu = \delta + \alpha \mu \quad \Rightarrow \quad \mu = \frac{\delta}{(1 - \alpha)}$$

- Por lo tanto el valor esperado de un ARMA(1,1) es el mismo de un AR(1).

$$\mathbb{E}[X_t] = \frac{\delta}{(1 - \alpha)}$$

## Promedio Móvil Auto Regresivo: Momentos de ARMA(1,1)

(2/2)

- Calculamos la auto-correlación del proceso estacionario  $X_t$ :

$$\rho_\tau = \mathbb{E}[X_{t-\tau} X_t] = \mathbb{E}[X_{t-\tau}(\delta + \alpha X_{t-1} + u_t - \beta u_{t-1})]$$

- Obteniendo la **función de autocorrelación**  $\rho_\tau$  como una fórmula recursiva:

$$\begin{cases} \rho_\tau = \alpha \rho_{\tau-1} \\ \rho_1 = \frac{(\alpha - \beta)(1 - \alpha\beta)}{1 + \beta^2 - 2\alpha\beta} \end{cases}$$

### ■ PREGUNTAS:





- ¿Qué sucede con  $\rho_\tau$  cuando  $\alpha = \beta$ ?
- ¿Qué podemos decir entonces de un modelo ARMA(1,1)  $X_t$  cuando  $\alpha = \beta$ ?

**EJERCICIO EN CLASE (5 minutos):** Obtener la varianza (equivalente al coeficiente de autocorrelación  $\rho_0$ ) de un ARMA(1,1) cuando  $\alpha = 1$  y  $\beta = 0$ .

## Promedio Móvil Auto Regresivo (2/2)

### Momentos de ARMA(1,1)

**Ejemplo:** Considérese a un proceso ARMA(1,1) generado con  $u_t$  v.a.'s i.i.d dadas por procesos aleatorios puros. Se muestran a continuación las funciones de auto-correlación  $\rho_\tau$  para diferentes combinaciones de  $\alpha$  y  $\beta$  tomando valores **0.8, 0.5, -0.5 y -0.8**.





**5 minutos ...**

# PLAN DE LA PRESENTACIÓN

## PARTE 1

- ❖ ANTECEDENTES
- ❖ SERIES DE TIEMPO
- ❖ DISTRIBUCIÓN DE SERIES DE TIEMPO
- ❖ CARACTERÍSTICAS DE LAS SERIES DE TIEMPO

## PARTE 2

- ❖ DESCOMPOSICIÓN
- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ EJEMPLO

## PARTE 3

- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ OTRAS CARACTERÍSTICAS
- ❖ PRONÓSTICOS



# OTRAS CARACTERÍSTICAS

## Causalidad (de Granger)

- **Correlación:** Al considerar a dos v.a.'s  $X$  y  $Y$ , su correlación refleja que cambios de una v.a. se deben reflejar también en la otra.
- **Correlaciones espurias:** Hay ejemplos para los cuales la correlación no hace sentido y se denominan espurias.
- **Alternativa:** Concepto de causalidad.
- **Causalidad a la Granger:**
  - Los modelos ARMA para  $X_t$ , tienen como consideración implícita el uso óptimo de información pasada  $D_t^x = \{x_{t-1}, x_{t-2}, \dots, x_0\}$ .
  - La idea consiste en que si un proceso  $X$  causa a  $Y$ , los valores actuales y rezagados de  $X_t$  deben contener información  $D_t^x$  que al usarse permita mejorar la predicción de  $Y_{t+\tau}$ , para  $\tau > 0$ .
  - Otra forma de entender la idea anterior es que la información para predecir  $Y_{t+\tau}$  no está solo contenida en su historia, sino también en la historia o distribución  $D_t^x$  del proceso  $X_t$ .






# OTRAS CARACTERÍSTICAS

## Cointegración: Grado de Integración

- Partamos de la regresión lineal siguiente, con  $u_t$  proceso aleatorio puro:



- Tenemos que  $y_t$  depende de  $x_t$  y del ruido generado por  $u_t$ .
- Conforme a Granger (1981), una simulación del lado derecho debe reproducir las propiedades de la variable observada  $y_t$ .
- Si por ejemplo  $y_t$  muestra ciclicidad, entonces  $x_t$  debe presentar también dicha ciclicidad, ya que la aleatoriedad de  $u_t$  no la incorporaría.
- Se define el concepto de **grado de integración**  $I(d)$  a partir de la idea de que diferenciando  $d$  veces una variable  $y_t$  pueda hacerse estacionaria. En tal caso se dirá que  $y_t$  tiene **grado de integración de orden**  $d$ :

Si  $y_t \sim I(d)$  significa que  $\Delta_d y_t$  es estacionaria.

# OTRAS CARACTERÍSTICAS

## Cointegración: Método de Representación de Granger

### ■ Propiedades del Grado de Integración :

- Si  $y_t$  es débilmente estacionaria entonces  $y_t \sim I(0)$ .
- Si  $y_t \sim I(1)$  entonces  $\Delta_1 y_t = y_t - y_{t-1} \sim I(0)$ .
- Si  $y_t \sim I(1)$  y  $z_t \sim I(0)$  entonces  $y_t + z_t \sim I(1)$  normalmente.

### ■ Variables Cointegradas: Se refiere a que dos procesos $I(1)$ al sumarlos resulten $I(0)$ .

### ■ Ejemplo: Sea $y_t = \alpha + \beta x_t + u_t$ con $u_t$ proceso aleatorio puro y supongamos que $y_t \sim I(1)$ y $x_t \sim I(1)$ . Entonces:

1. Sabemos que  $u_t \sim I(0)$  por ser estacionario.
2. Resulta que  $y_t - \beta x_t \sim I(0)$  por como definimos a  $y_t$ .
3. Del caso anterior,  $\beta$  es única para que se presente esta situación, ya que:

Asumiendo que  $y_t = \beta_1 x_t + u_{1,t}$  y  $y_t = \beta_2 x_t + u_{2,t}$ , entonces resulta que  $\beta_2 = \beta_1$ :

$$(\beta_2 - \beta_1)x_t = u_{1,t} - u_{2,t}$$

$I(1)$  a menos  
que  $\beta_2 = \beta_1$

$I(0)$  ya que la  
diferencia es  
estacionaria

# OTRAS CARACTERÍSTICAS

## Teorema de Representación de Granger

### ■ Definición formal de causalidad de Granger (1969):

— **Supuestos:** Sea  $D_t^x = \{x_t, x_{t-1}, \dots, x_0\}$  la información de proceso  $X_t$  al tiempo  $t$ ,  $D_t^y$  la correspondiente al proceso  $Y_t$  y  $D_t^* = \{x_t, \dots, x_0, y_t, \dots, y_0\}$  la información total de ambos procesos.

— **Métrica para errores:** Sea  $\sigma^2(y_{t+1})$  la varianza del error por predicción de  $y_{t+1}$  en el tiempo  $t$ :  
$$\sigma^2(y_{t+1}) = \mathbb{E}[(\hat{y}_{t+1} - y_{t+1})^2]$$

— **Causalidad de Granger:**  $x$  causa a  $y$  si y solo si la predicción óptima lineal cumple:

$$\sigma^2(y_{t+1}|D_t^*) < \sigma^2(y_{t+1}|D_t^y)$$

■ **Interpretación:** Los valores de  $y$  pueden predecirse mejor al adicionar la información actual y anterior de  $x$ .

## Teorema de Representación de Granger

Ilustración del Teorema de Representación de Granger y Weiss (1983)

- Considérese el siguiente sistema de  $\mathbf{AR}(p)$ , con  $u_{1,t}$  y  $u_{2,t}$  procesos aleatorios puros:

$$\begin{aligned}x_t &= \sum_{j=1}^p a_{1,j} x_{t-j} + \sum_{j=1}^p b_{1,j} y_{t-j} + u_{1,t} \\y_t &= \sum_{j=1}^p a_{2,j} x_{t-j} + \sum_{j=1}^p b_{2,j} y_{t-j} + u_{2,t}\end{aligned}$$

- Si  $x_t$  y  $y_t$  son I(1) y cointegradas, entonces el sistema puede reescribirse como:

$$\begin{aligned}\Delta x_t &= \alpha_1 (y_{t-1} - \beta x_{t-1}) \sum_{j=1}^{p-1} a_{1,j}^* \Delta x_{t-j} + \sum_{j=1}^{p-1} b_{1,j}^* \Delta y_{t-j} + u_{1,t} \\ \Delta y_t &= \alpha_2 (y_{t-1} - \beta x_{t-1}) \sum_{j=1}^{p-1} a_{2,j}^* \Delta x_{t-j} + \sum_{j=1}^{p-1} b_{2,j}^* \Delta y_{t-j} + u_{2,t}\end{aligned}$$


con al menos algún  $\alpha_1$  o  $\alpha_2$  distinto de cero.

- En este caso se tiene que ambas partes de las ecuaciones están equilibradas y tienen orden de integración I(0).


# OTRAS CARACTERÍSTICAS

## Heteroskedasticidad: Antecedentes

- **Heteroskedasticidad** proviene del griego antiguo *hetero* “diferente” y *skedasis* “dispersión” (<https://en.wikipedia.org/wiki/Heteroscedasticity>)
- La **heteroskedasticidad** es una característica observada en muchas series de tiempo de datos reales, con la volatilidad (dispersión) variando en el tiempo.
- **Ejemplo:** Tomemos el índice accionario del mercado alemán (DAX), consistente en 842 observaciones diarias del 2/01/1996 al 19/05/1999:



a) German Stock Market Index: Data



b) German Stock Market Index: Continuous returns


# OTRAS CARACTERÍSTICAS

## Heteroskedasticidad: Ejemplo


- Se aprecia en el histograma que la distribución de los rendimientos presenta kurtosis de **6.3**, superior al **3.0** que se esperaría para una distribución normal.
- El correlograma o ACF muestra un **orden 2** de auto-correlación.
- Al estimar un modelo **AR(2)** para los rendimientos observados, se obtienen la siguiente estimación:

$$\Delta \ln(\text{DAX}_t) = 0.001 - 0.090 \Delta \ln(\text{DAX}_{t-2}) + \varepsilon_t$$


- Pero cuando se calcula la ACF para el cuadrado de los residuos  $\varepsilon_t^2$ , se observa que los datos no son estacionarios. Esto indica que hay un **segundo momento (varianza) con autocorrelación**.



c) German Stock Market Index: Histogram of the continuous returns



d) Estimated autocorrelations of the residuals



e) Estimated autocorrelations of the squared residuals

## Modelo ARCH: Introducción

(Auto Regresive Conditional Heteroskedasticity)

- Un ejemplo de modelo ARCH estaría dado por la siguiente relación lineal:

$$y_t = \beta x_t + \varepsilon_t$$

- Con la posibilidad de que la variable  $x_t$  pueda contener variables endógenas con rezago:

$$x_t = \sum_{j=1}^p a_j x_{t-j}$$

- El término de error  $\varepsilon_t$  tiene media cero y varianza estacionarias:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \mathbb{E}[\varepsilon_t^2] = \sigma^2$$

- Se asume que  $\varepsilon_t$  no es auto-correlacionada, sin embargo  $\varepsilon_t^2$  si presenta auto-correlación, representada por un modelo AR( $q$ ):

$$\varepsilon_t^2 = \alpha_0 + \sum_{j=1}^q \alpha_j \varepsilon_{t-j}^2 + \omega_t$$

con  $\omega_t$  un proceso aleatorio puro,  $\alpha_0 > 0$ ,  $\alpha_q > 0$  y  $\alpha_i \geq 0$  para  $i = 1, \dots, q-1$ .

# PLAN DE LA PRESENTACIÓN

## PARTE 1

- ❖ ANTECEDENTES
- ❖ SERIES DE TIEMPO
- ❖ DISTRIBUCIÓN DE SERIES DE TIEMPO
- ❖ CARACTERÍSTICAS DE LAS SERIES DE TIEMPO

## PARTE 2

- ❖ DESCOMPOSICIÓN
- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ EJEMPLO

## PARTE 3

- ❖ MODELOS DE SERIES DE TIEMPO
- ❖ OTRAS CARACTERÍSTICAS
- ❖ PRONÓSTICOS





## Predicción con ARMA: mediante mínimos cuadrados. (1/2)

- En los años 1970 tuvo gran auge el enfoque predictivo propuesto por **Box-Jeknins** que se describe a continuación debido a la simplicidad del método comparado otros modelos econométricos con muchas variables, resultando estos últimos más engorrosos.
- Se asumirá que todas las observaciones previas y hasta el tiempo  $t$  son conocidas:

*Serie de datos conocidos:  $\{x_t, x_{t-1}, \dots, x_0\}$*

- Denotaremos a  $\hat{X}_t(\tau)$  como el estimador en el periodo  $t$ , de la serie  $\tau$  periodos en el futuro correspondientes a  $x_{t+\tau}$ .
- El estimador  $\hat{X}_t(\tau)$  se obtiene de forma recursiva...

## Predicción con ARMA: mediante mínimos cuadrados. (2/2)

- Realizando la predicción a un periodo, quedaría el estimador de la siguiente manera:

$$\hat{X}_t(1) = \delta + \alpha x_t - \beta u_t$$

- Si consideramos que

$$\hat{X}_0(1) = \delta + \alpha x_0 - \beta u_0$$

Tomado al error de la predicción  $u_1 = x_1 - \hat{X}_0(1)$ , resulta al combinarlos que:

$$\hat{X}_1(1) = \delta(1 + \beta) + (\alpha - \beta)x_1 + \alpha\beta x_0 - \beta^2 u_0$$

- Procediendo de esta forma para los siguientes periodos de tiempo  $t$  se obtiene que:

$$\hat{X}_t(1) = \delta \sum_{j=0}^t \beta^j + \sum_{j=0}^{t-1} \beta^j (\alpha - \beta) x_{t-j} + \beta^t \alpha x_0 - \beta^{t+1} u_0$$


# CONCLUSIONES

## REFLEXIONES FINALES

- **Series de tiempo e inferencia estadística:** Se volvieron un estándar en la modelación de fenómenos económicos o econometría (**Haavelmo et. al.**) y en otras disciplinas también (medicina, farmacéutica, psicología, etc.).
- **Modelos Autoregresivos:** Resultaron ser útiles para representar fenómenos económicos más complejos (**Engle y Granger et. al.**).
- **Predicción:** Se antoja extrapolar al futuro con esto modelos... Causalidad vs Predicción (**Granger et. al.**)
- **Paradojas sobre predicción:** Es fundamental la independencia de las v.a.'s (ejemplo de **Sornette y Andersen**). Si se pudiera predecir ahora, cualquier incorporación de dicha predicción en la práctica implicaría cambios en el futuro, afectándose la veracidad de la predicción original...
- **Conclusión:** ... ¡Hay que tomar en cuenta la información disponible! ... ¡y saber utilizarla!

*“Si sale sol, le ponemos un bypas cuádruple.  
Si cae águila, se toma un desenfriolito.”*





# MÓDULO DE ESTADÍSTICA SERIES DE TIEMPO

**DIPLOMADO DE  
MATEMÁTICAS Y  
ESTADÍSTICA, MIDE**

Roslán Gómez Nesterkín  
Noviembre 2021